Predição da Temperatura Crítica de Supercondutores Usando Machine Learning

Matheus da Costa Geraldes

Universidade do estado do Rio de Janeiro - Instituto de Física Armando Dias Tavares / Estado sólido

June 18, 2025

Roteiro

1. Introdução e Motivação
2. Metodologia
   - Conceitos e Modelos de Machine Learning
3. Resultados
4. Conclusão

O que são Supercondutores?

- São Materiais que conduzem eletricidade com **resistência elétrica nula** abaixo de uma temperatura crítica (T_c).
- **Aplicações transformadoras:**
  - Imagens por Ressonância Magnética (MRI) na medicina.
  - Ímãs poderosos em aceleradores de partículas como o LHC no CERN.

Figure: Eletroímãs supercondutores do LHC.

A Física por Trás: Como isso acontece?

Fenômeno Quântico na Rede Cristalina

A supercondutividade convencional (Teoria BCS) é explicada pela formação dos **Pares de Cooper**.

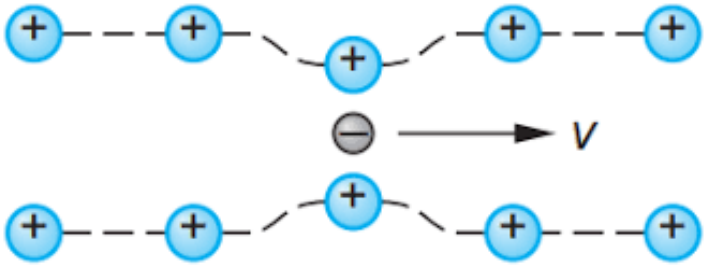

- Um elétron (e^-) que se move pela rede cristalina atrai íons positivos, criando uma distorção local com carga positiva.

A Física por Trás: Como isso acontece?

Fenômeno Quântico na Rede Cristalina

A supercondutividade convencional (Teoria BCS) é explicada pela formação dos **Pares de Cooper**.

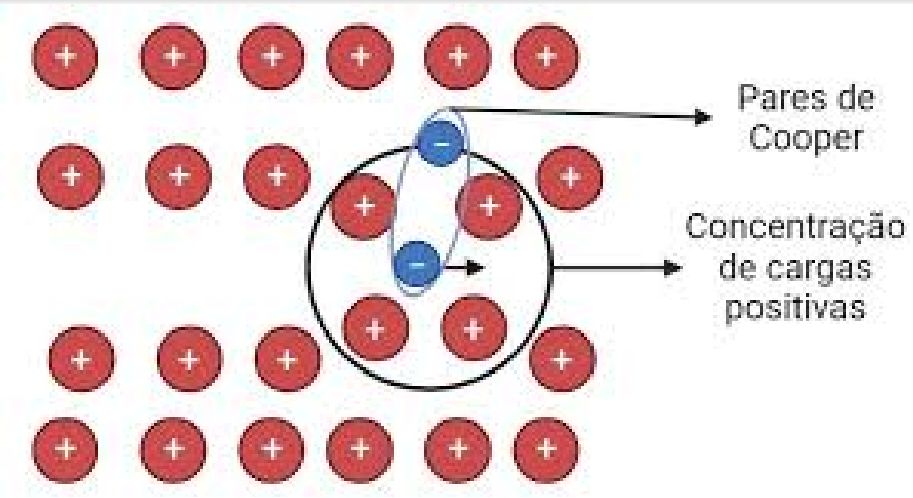

- Um elétron (e^-) que se move pela rede cristalina atrai íons positivos, criando uma distorção local com carga positiva.
- Essa região de carga positiva atrai um segundo elétron, formando um par ligado ($e^- \leftrightarrow e^-$) através de uma vibração da rede (fônon).

A Física por Trás: Como isso acontece?

Fenômeno Quântico na Rede Cristalina

A supercondutividade convencional (Teoria BCS) é explicada pela formação dos **Pares de Cooper**.

- Um elétron (e^-) que se move pela rede cristalina atrai íons positivos, criando uma distorção local com carga positiva.
- Essa região de carga positiva atrai um segundo elétron, formando um par ligado ($e^- \leftrightarrow e^-$) através de uma vibração da rede (fônon).
- Esses pares se comportam como **bósons** e podem todos ocupar o **mesmo estado quântico de energia mínima**, formando um *condensado*.

A Física por Trás: Como isso acontece?

Fenômeno Quântico na Rede Cristalina

A supercondutividade convencional (Teoria BCS) é explicada pela formação dos **Pares de Cooper**.

- Um elétron (e^-) que se move pela rede cristalina atrai íons positivos, criando uma distorção local com carga positiva.
- Essa região de carga positiva atrai um segundo elétron, formando um par ligado ($e^- \leftrightarrow e^-$) através de uma vibração da rede (fônon).
- Esses pares se comportam como **bósons** e podem todos ocupar o **mesmo estado quântico de energia mínima**, formando um *condensado*.
- Neste estado coerente, os pares se movem como um único "super-elétron", sem interagir com as imperfeições da rede. O resultado é a **resistência zero**.

Supercondutividade e Temperatura

1. O Efeito da Temperatura na Rede Cristalina

Em temperaturas normais, os íons de uma rede cristalina não estão parados; eles vibram intensamente em torno de suas posições fixas. Essa vibração é a agitação térmica (ou "desordem térmica").

Supercondutividade e Temperatura

1. O Efeito da Temperatura na Rede Cristalina

Em temperaturas normais, os íons de uma rede cristalina não estão parados; eles vibram intensamente em torno de suas posições fixas. Essa vibração é a agitação térmica (ou "desordem térmica").

- Quanto maior a temperatura, mais caótica e energética é essa vibração.

Supercondutividade e Temperatura

1. O Efeito da Temperatura na Rede Cristalina

Em temperaturas normais, os íons de uma rede cristalina não estão parados; eles vibram intensamente em torno de suas posições fixas. Essa vibração é a agitação térmica (ou "desordem térmica").

- Quanto maior a temperatura, mais caótica e energética é essa vibração.
- Essas vibrações quânticas são chamadas de **fônons**.

Supercondutividade e Temperatura

1. O Efeito da Temperatura na Rede Cristalina

Em temperaturas normais, os íons de uma rede cristalina não estão parados; eles vibram intensamente em torno de suas posições fixas. Essa vibração é a agitação térmica (ou "desordem térmica").

- Quanto maior a temperatura, mais caótica e energética é essa vibração.
- Essas vibrações quânticas são chamadas de **fônons**.

2. Par de Cooper

O par de Cooper ($e^- \leftrightarrow e^-$) é uma ligação fraca, com uma energia de ligação específica, conhecida como "*gap*" de energia, mediada pela deformação da rede (o fônon).

Supercondutividade e Temperatura

3. Por que o Resfriamento é Essencial?

Supercondutividade e Temperatura

3. **Por que o Resfriamento é Essencial?**
   - **Redução do "Ruído" Térmico:** O resfriamento minimiza as vibrações atômicas incoerentes, permitindo que essa interação indireta aconteça.

Supercondutividade e Temperatura

3. **Por que o Resfriamento é Essencial?**
   - **Redução do "Ruído" Térmico:** O resfriamento minimiza as vibrações atômicas incoerentes, permitindo que essa interação indireta aconteça.
   - **Acima da Temperatura Crítica:** A energia da agitação térmica é maior que a energia do *"gap"*. Assim, mesmo que um Par de Cooper consiga se formar, ele é imediatamente quebrado ("aniquilado") pelo caos térmico.

Supercondutividade e Temperatura

3. **Por que o Resfriamento é Essencial?**
   - **Redução do "Ruído" Térmico:** O resfriamento minimiza as vibrações atômicas incoerentes, permitindo que essa interação indireta aconteça.
   - **Acima da Temperatura Crítica:** A energia da agitação térmica é maior que a energia do *"gap"*. Assim, mesmo que um Par de Cooper consiga se formar, ele é imediatamente quebrado ("aniquilado") pelo caos térmico.
   - **Abaixo da Temperatura Crítica:** A energia térmica disponível é menor que a energia do *"gap"*. Portanto, uma vez que um Par de Cooper é formado, ele se torna estável e não é mais destruído pelas vibrações da rede.

Implicações do Estado Supercondutor

O estado coerente dos Pares de Cooper resulta em propriedades únicas:

- **Gap de Energia (Δ):** Existe uma energia mínima necessária para quebrar um Par de Cooper. Este "gap" protege o estado supercondutor de perturbações de baixa energia (como vibrações térmicas). A T_c é diretamente proporcional a este gap.

Implicações do Estado Supercondutor

O estado coerente dos Pares de Cooper resulta em propriedades únicas:

- **Gap de Energia (Δ):** Existe uma energia mínima necessária para quebrar um Par de Cooper. Este "gap" protege o estado supercondutor de perturbações de baixa energia (como vibrações térmicas). A T_c é diretamente proporcional a este gap.
- **Efeito Meissner:** Um supercondutor, **ele expulsa completamente o campo magnético de seu interior**. Para isso, ele gera correntes de superfície que criam um campo oposto ao do ímã.

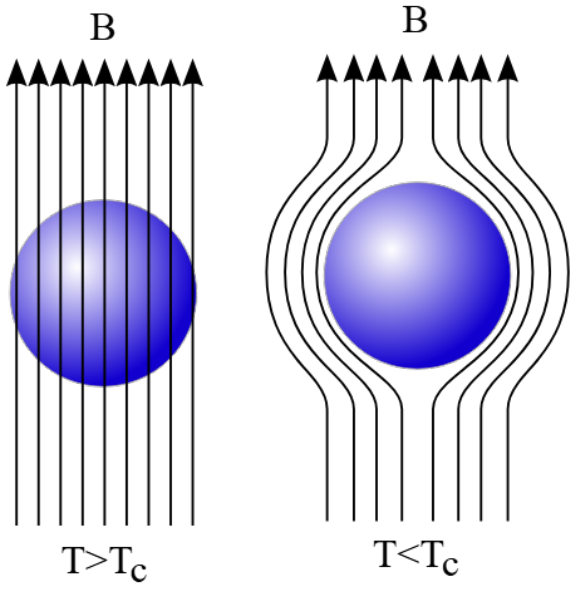

O Desafio Científico: A Complexidade do Mecanismo

- A **Teoria BCS** explica muito bem os supercondutores "convencionais" de baixa temperatura.

O Desafio Científico: A Complexidade do Mecanismo

- A **Teoria BCS** explica muito bem os supercondutores "convencionais" de baixa temperatura.
- **O Quebra-Cabeça:** Nos anos 80, foram descobertos os supercondutores de **alta temperatura** (como os cupratos), com T_c muito altas para serem explicadas apenas pela Teoria BCS.

O Desafio Científico: A Complexidade do Mecanismo

- A **Teoria BCS** explica muito bem os supercondutores "convencionais" de baixa temperatura.
- **O Quebra-Cabeça:** Nos anos 80, foram descobertos os supercondutores de **alta temperatura** (como os cupratos), com T_c muito altas para serem explicadas apenas pela Teoria BCS.
- **Problema em Aberto:** O mecanismo exato por trás da supercondutividade de alta temperatura é um dos **problemas não resolvidos da física da matéria condensada**. Ele pode envolver interações magnéticas, de spin ou outros efeitos quânticos complexos.

A falta de uma teoria completa nos impede de projetar novos materiais supercondutores "do zero".

O Desafio Prático: A Barreira da Temperatura

A viabilidade das aplicações depende criticamente da temperatura .

Marcos de Temperatura:

- **Hélio Líquido (4 K):**
  Necessário para os primeiros supercondutores. Extremamente caro e difícil de manusear.

O Desafio Prático: A Barreira da Temperatura

A viabilidade das aplicações depende criticamente da temperatura .

Marcos de Temperatura:

- **Hélio Líquido (4 K):**
  Necessário para os primeiros supercondutores. Extremamente caro e difícil de manusear.
- **Nitrogênio Líquido (77 K):**
  Um marco crucial. É barato e abundante, viabilizando aplicações como a ressonância magnética.

O Desafio Prático: A Barreira da Temperatura

A viabilidade das aplicações depende criticamente da temperatura .

Marcos de Temperatura:

- **Hélio Líquido (4 K):** Necessário para os primeiros supercondutores. Extremamente caro e difícil de manusear.
- **Nitrogênio Líquido (77 K):** Um marco crucial. É barato e abundante, viabilizando aplicações como a ressonância magnética.
- **Temperatura Ambiente ($\approx$ 300 K):** O "Santo Graal" da pesquisa. Um material com essa propriedade causaria uma revolução tecnológica.

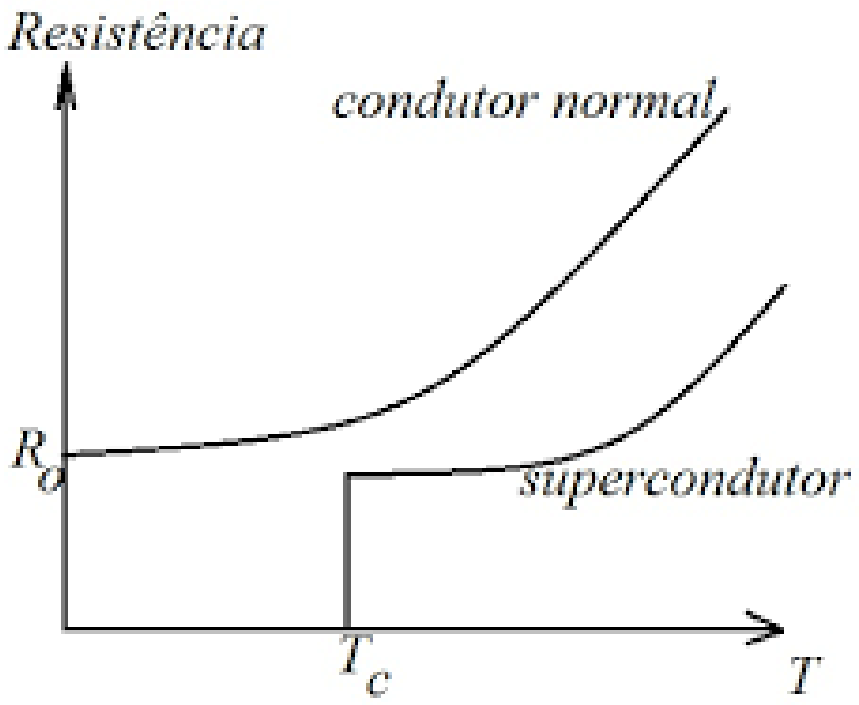

Figure: Temperatura pela resistividade.

Objetivo e Dados

Objetivo Principal: Construir um modelo estatístico orientado por dados (Data-Driven Statistical Model), baseado principalmente em dados empíricos (ou seja, dados coletados a partir de observações, experimentos ou registros históricos), utilizando técnicas de análise de dados e aprendizado de máquina (Machine Learning) para prever a temperatura crítica (T_c) de um supercondutor, com base apenas em sua fórmula química.

Fonte dos Dados:

- **Base de Dados:** Superconducting Material Database do NIMS (Japão).
- **Tamanho Final:** Após um processo extenso de limpeza e validação, utilizamos um conjunto de dados com **21.263 supercondutores**.

Engenharia de Features

Como transformar uma fórmula química (ex: $YBa_2Cu_3O_7$) em números que um modelo entenda?

- Extraímos **81 características numéricas** de cada material.
- Essas características são baseadas em 8 propriedades fundamentais dos elementos químicos, como:
  - Massa Atômica
  - Raio Atômico
  - Valência
  - **Condutividade Térmica**
  - Afinidade Eletrônica
  - Energia de Ionização
  - Densidade
  - Calor de Fusão
- Para cada propriedade, calculamos estatísticas como média, desvio padrão, entropia, etc.

O que é Machine Learning (ML)?

Definição

É a ciência de ensinar computadores a **aprender padrões a partir de dados**, sem serem explicitamente programados para cada tarefa.

Tipos de Machine Learning:

- **Supervisionado:** Usa dados rotulados para prever saídas. Exemplos: Regressão Linear, SVM, Redes Neurais.

O que é Machine Learning (ML)?

Definição

É a ciência de ensinar computadores a **aprender padrões a partir de dados**, sem serem explicitamente programados para cada tarefa.

Tipos de Machine Learning:

- **Supervisionado:** Usa dados rotulados para prever saídas. Exemplos: Regressão Linear, SVM, Redes Neurais.
- **Não Supervisionado:** Descobre padrões em dados não rotulados. Exemplos: Clusterização, PCA, Autoencoders.

O que é Machine Learning (ML)?

Definição

É a ciência de ensinar computadores a **aprender padrões a partir de dados**, sem serem explicitamente programados para cada tarefa.

Tipos de Machine Learning:

- **Supervisionado:** Usa dados rotulados para prever saídas. Exemplos: Regressão Linear, SVM, Redes Neurais.
- **Não Supervisionado:** Descobre padrões em dados não rotulados. Exemplos: Clusterização, PCA, Autoencoders.
- **Semi-Supervisionado:** Combina poucos dados rotulados com muitos não rotulados para melhorar o aprendizado.

O que é Machine Learning (ML)?

Definição

É a ciência de ensinar computadores a **aprender padrões a partir de dados**, sem serem explicitamente programados para cada tarefa.

Tipos de Machine Learning:

- **Supervisionado:** Usa dados rotulados para prever saídas. Exemplos: Regressão Linear, SVM, Redes Neurais.
- **Não Supervisionado:** Descobre padrões em dados não rotulados. Exemplos: Clusterização, PCA, Autoencoders.
- **Semi-Supervisionado:** Combina poucos dados rotulados com muitos não rotulados para melhorar o aprendizado.
- **Por Reforço:** Aprende com tentativa e erro, maximizando recompensas. Aplicações em jogos, robótica, etc.

Machine Learning Supervisionado

- No **Aprendizado Supervisionado** (o nosso caso), nós fornecemos ao modelo:
  - **Features (X):** Os dados de entrada (as 81 propriedades).
  - **Labels (y):** As respostas corretas (a T_c conhecida).
- A tarefa específica de prever um valor numérico (como a temperatura) é chamada de **Regressão**.

O que é Deep Learning?

- É um **subcampo** especializado do Machine Learning.
- Sua principal característica é o uso de **Redes Neurais Artificiais** com múltiplas camadas (por isso, "profundo" ou *deep*).
- Essas redes são inspiradas na estrutura de neurônios do cérebro humano.
- **Força:** São excelentes para aprender padrões extremamente complexos e não-lineares, especialmente com grandes volumes de dados. O nosso modelo MLP é um exemplo de Deep Learning.

Por que usar Machine Learning?

O problema é a escala:

- O número de combinações de elementos químicos para criar novos materiais é astronomicamente grande.
- Sintetizar e testar **um único material** em laboratório é um processo lento, caro e complexo. É inviável testar todos os candidatos.

O Papel do ML

O modelo de Machine Learning funciona como um **filtro ou GPS** para os cientistas.

- Ele analisa milhares de fórmulas *hipotéticas* no computador (custo muito baixo).
- Prevê quais são as mais promissoras.
- Guia o trabalho de laboratório para focar apenas nos melhores candidatos, economizando tempo e recursos.

Para que treinar com dados já conhecidos?

Se já sabemos a T_c dos materiais do dataset, por que usá-los?

- O objetivo é **ensinar o modelo**. Usamos os dados conhecidos como exemplos para que o modelo aprenda os padrões.

Analogia: Ensinando uma Criança a Reconhecer Gatos

Você mostra centenas de fotos de gatos (os *dados de treino*) para que ela aprenda o que é um gato. O objetivo é que ela consiga identificar um gato que **nunca viu antes** (a *predição*).

- Nosso modelo aprendeu com 21.263 "fotos" de supercondutores para ser capaz de olhar para uma fórmula química **nova e hipotética** e prever sua T_c.

Modelo 1: Regressão Linear

Como funciona?

Tenta encontrar a **melhor linha reta** (ou um plano, em múltiplas dimensões) que se ajusta aos dados. É o modelo mais simples.

$$T_c \approx w_1 \times (\text{feature}_1) + w_2 \times (\text{feature}_2) + \cdots + b$$

Papel no Projeto

Serviu como nosso **benchmark**: um ponto de partida simples para medir o ganho de performance dos modelos mais avançados.

Modelo 2: XGBoost

Como funciona?

Baseado em **Árvores de Decisão** e na técnica de *Boosting*.

Analogia: Um Time de Especialistas

1. O primeiro especialista (uma árvore simples) faz uma previsão inicial.
2. O segundo especialista foca nos **erros** do primeiro e tenta corrigi-los.
3. O terceiro corrige os erros dos dois primeiros, e assim por diante.
4. A previsão final é uma **combinação ponderada** da opinião de todos os especialistas.

Papel no Projeto

Nosso principal competidor. É conhecido por ser extremamente eficaz para dados estruturados/tabulares como o nosso.

Modelo 3: MLP (Rede Neural)

Como funciona?

Organizado em camadas de "neurônios" artificiais.

- **Camada de Entrada:** Recebe as 81 features do material.
- **Camadas Ocultas:** O "cérebro" do modelo. Os neurônios combinam as informações, aplicam funções matemáticas e passam o resultado adiante, aprendendo progressivamente padrões cada vez mais complexos.
- **Camada de Saída:** Produz a previsão final da temperatura crítica.

Papel no Projeto

Nosso modelo de Deep Learning. Representa uma abordagem diferente e poderosa, capaz de modelar qualquer relação complexa entre as features e o alvo.

Métricas de Avaliação

Para avaliar o desempenho dos modelos de regressão, foram utilizadas duas métricas principais:

Métricas de Avaliação

Para avaliar o desempenho dos modelos de regressão, foram utilizadas duas métricas principais:

- **RMSE (Root Mean Squared Error):**
  - Mede o erro médio entre os valores reais (y_i) e os valores previstos ($\hat{y}_i$).
  - Fórmula:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

  - Quanto menor o RMSE, melhor o desempenho do modelo.
  - Tem a mesma unidade da variável de saída.

Métricas de Avaliação

Para avaliar o desempenho dos modelos de regressão, foram utilizadas duas métricas principais:

- **RMSE (Root Mean Squared Error):**
  - Mede o erro médio entre os valores reais (y_i) e os valores previstos ($\hat{y}_i$).
  - Fórmula:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

  - Quanto menor o RMSE, melhor o desempenho do modelo.
  - Tem a mesma unidade da variável de saída.
- **R^2 (Coeficiente de Determinação):**
  - Indica o quanto da variação dos dados o modelo consegue explicar.
  - Fórmula:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

  - Onde $\bar{y}$ é a média dos valores reais.
  - Varia entre $-\infty$ e 1. Quanto mais próximo de 1, melhor.
  - Um R^2 alto significa que o modelo tem bom poder explicativo.

Comparação de Desempenho dos Modelos

Métricas de Performance no Conjunto de Teste

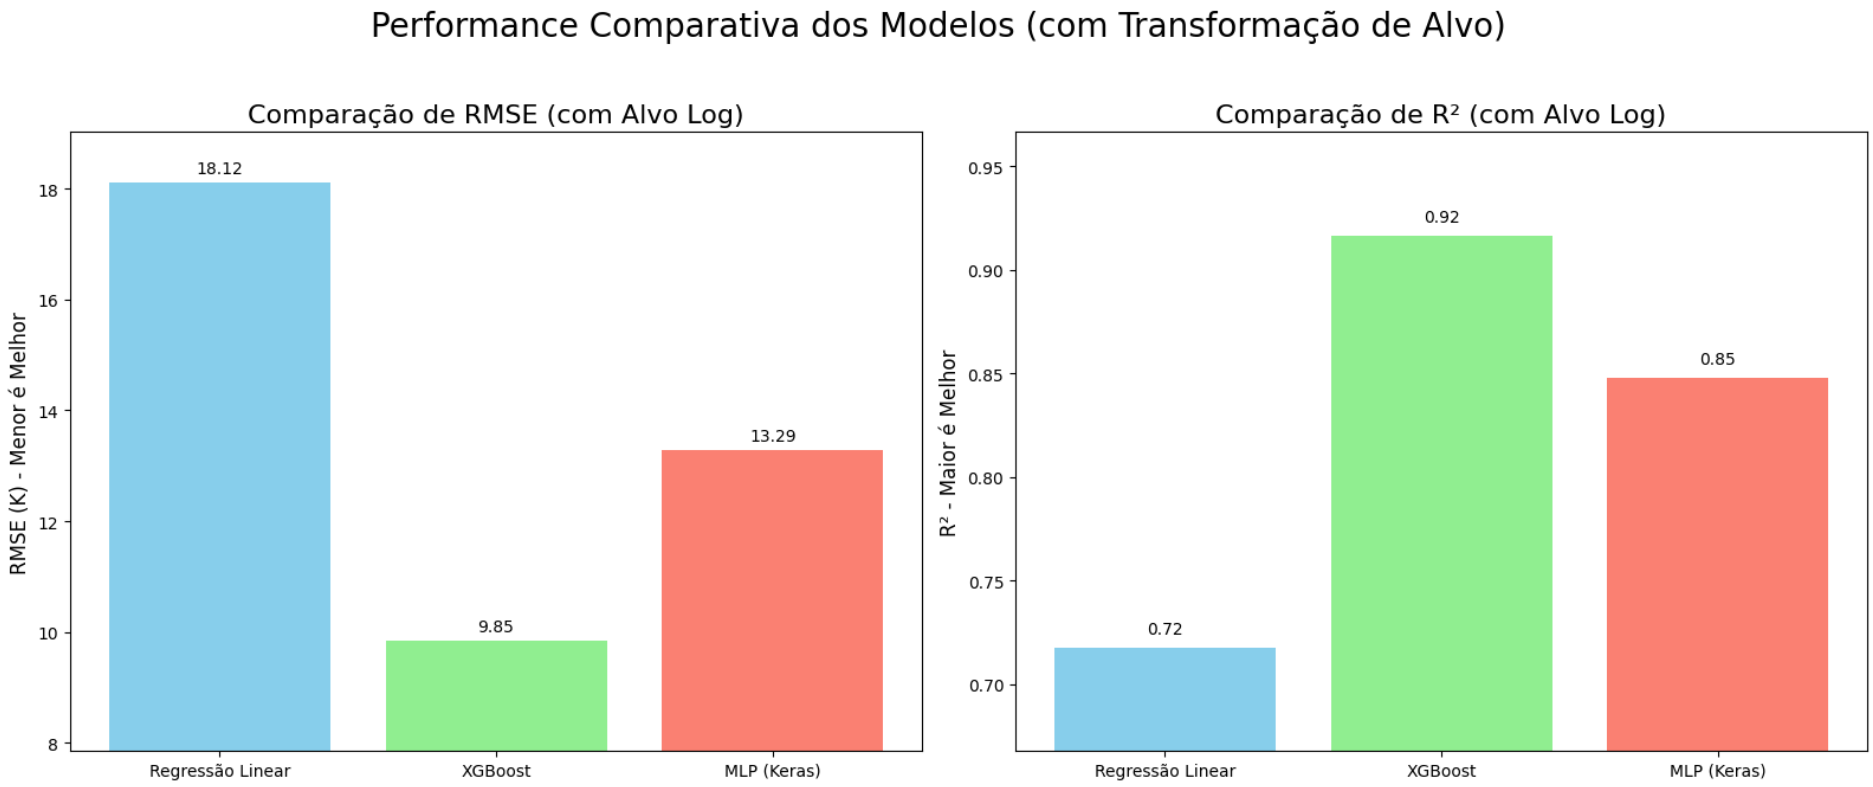

- **RMSE (Erro Médio):** O XGBoost teve o menor erro, prevendo a T_c com um erro médio de $\approx$ 9.5 K.
- **R² (Ajuste):** O XGBoost explicou 92% da variação nos dados, mostrando um ajuste excelente.

Importância das Features (XGBoost)

O que o melhor modelo (XGBoost) aprendeu? Quais são as propriedades mais importantes?

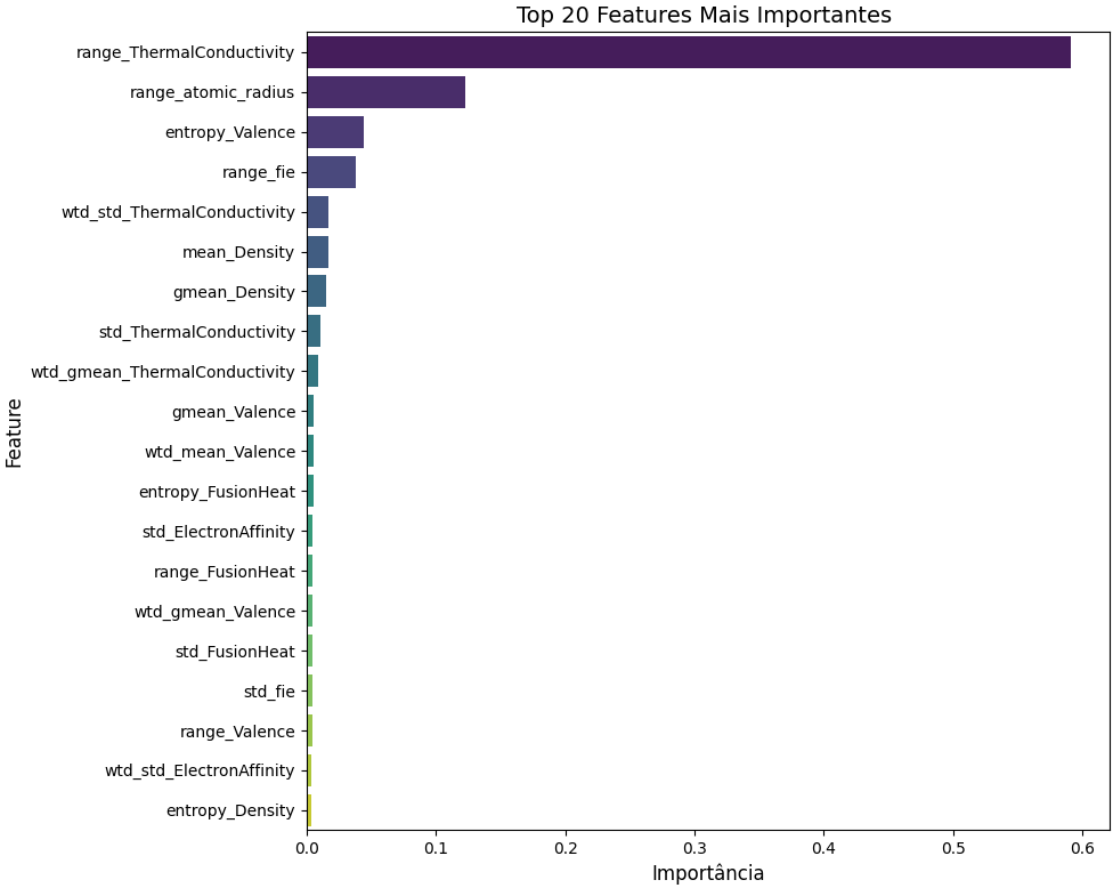

A **condutividade térmica** dos elementos se destacou como a característica mais influente, um insight físico valioso extraído pelo modelo.

Previsões vs. Valores Reais (MLP)

Este gráfico mostra a precisão do MLP em amostras individuais.

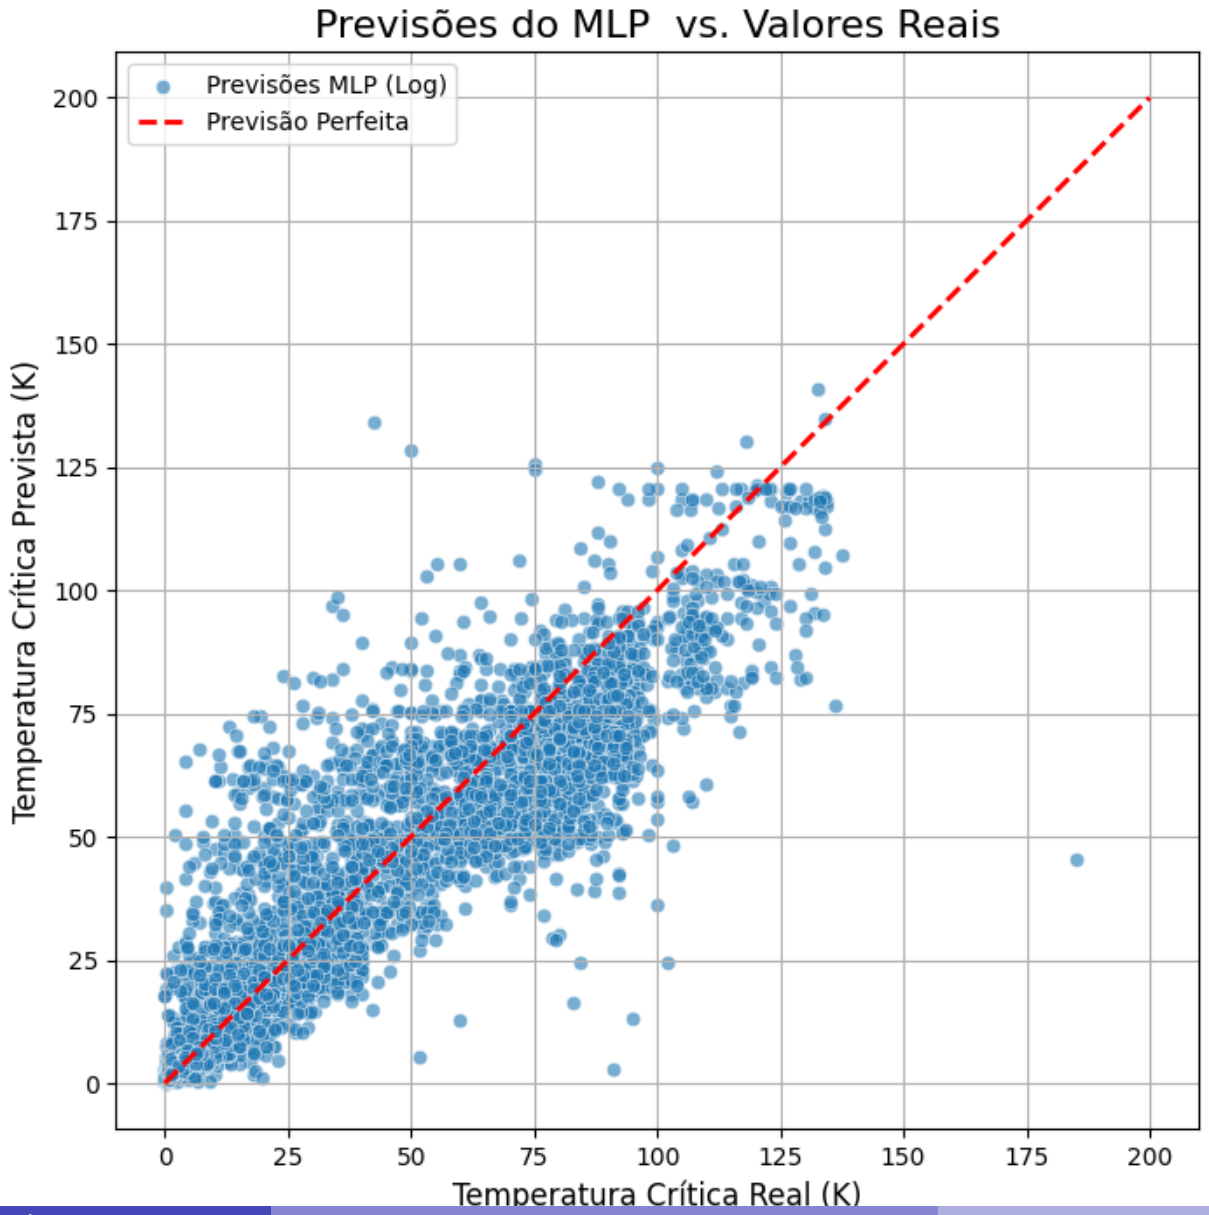

Previsões vs. Valores Reais (XGBoost)

Este gráfico mostra a precisão do XGBoost em amostras individuais.

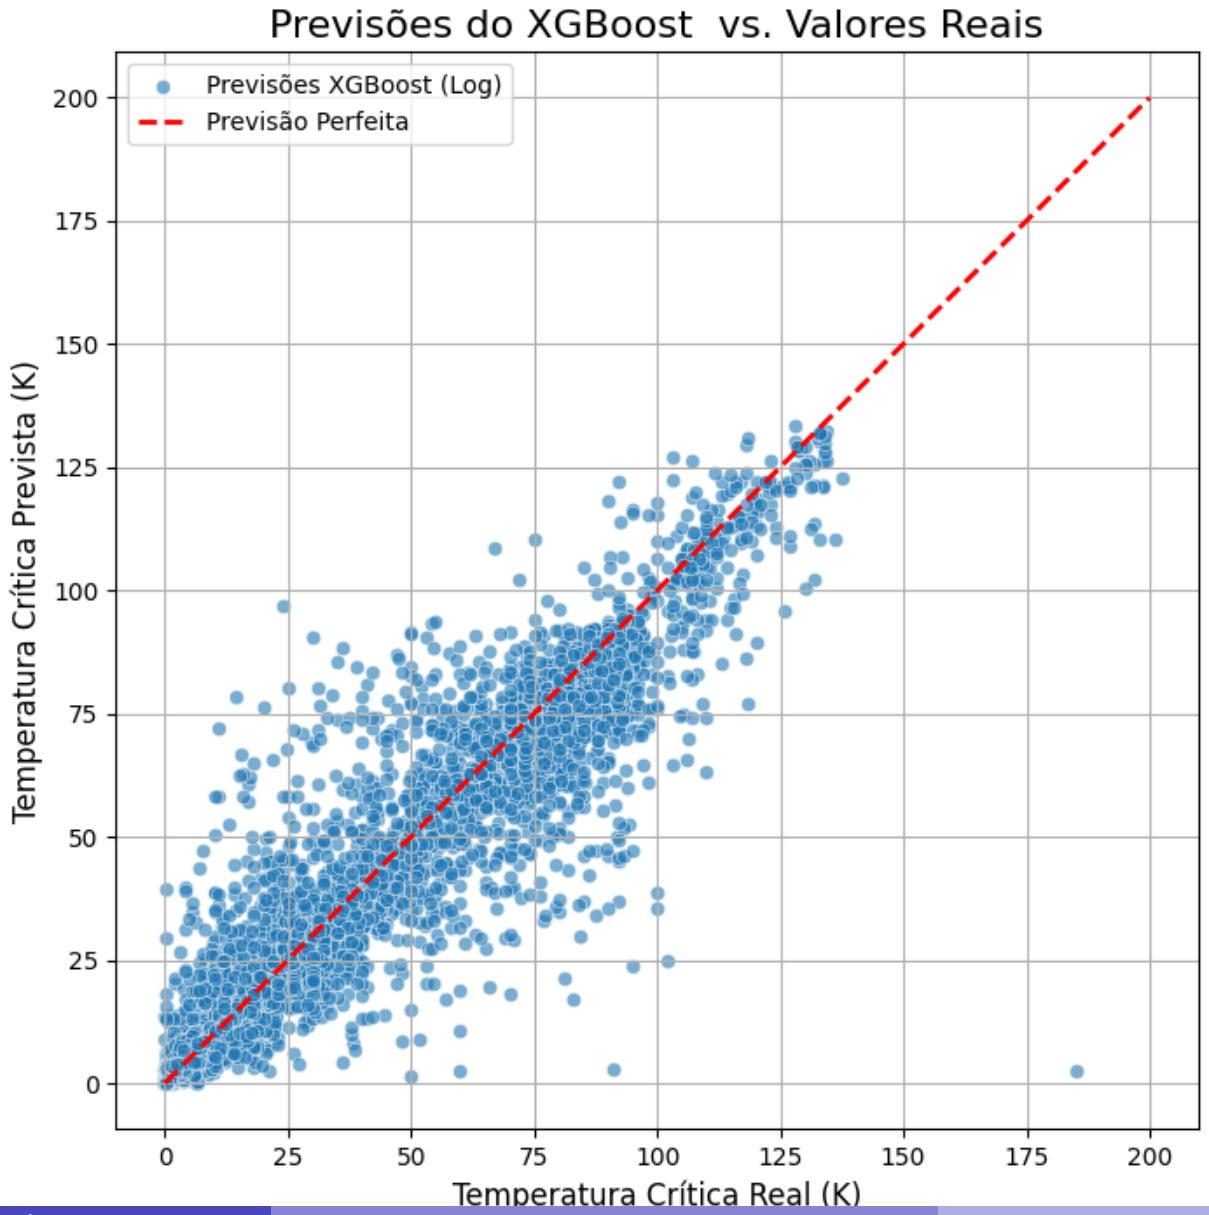

Comparação de Predições

Material	Temperatura Real (K)	Previsão XGBoost (K)	Previsão MLP (K)	Previsão Linear (K)
Bi0.02Sn0.98	3.85	3.76	4.68	3.59
Bi2Sr1.56La0.44Cu1O6	33.00	25.24	22.27	23.38
Pb2Sr2Y0.7Ca0.3Cu3O8	76.80	73.82	56.97	49.48
Mg0.99Pb0.01B2	35.90	32.63	52.46	82.78
Nb1C0.5Ni0.5	17.30	5.08	4.23	5.92

Distribuição das Previsões

O XGBoost foi o modelo que melhor replicou a distribuição estatística real dos dados.

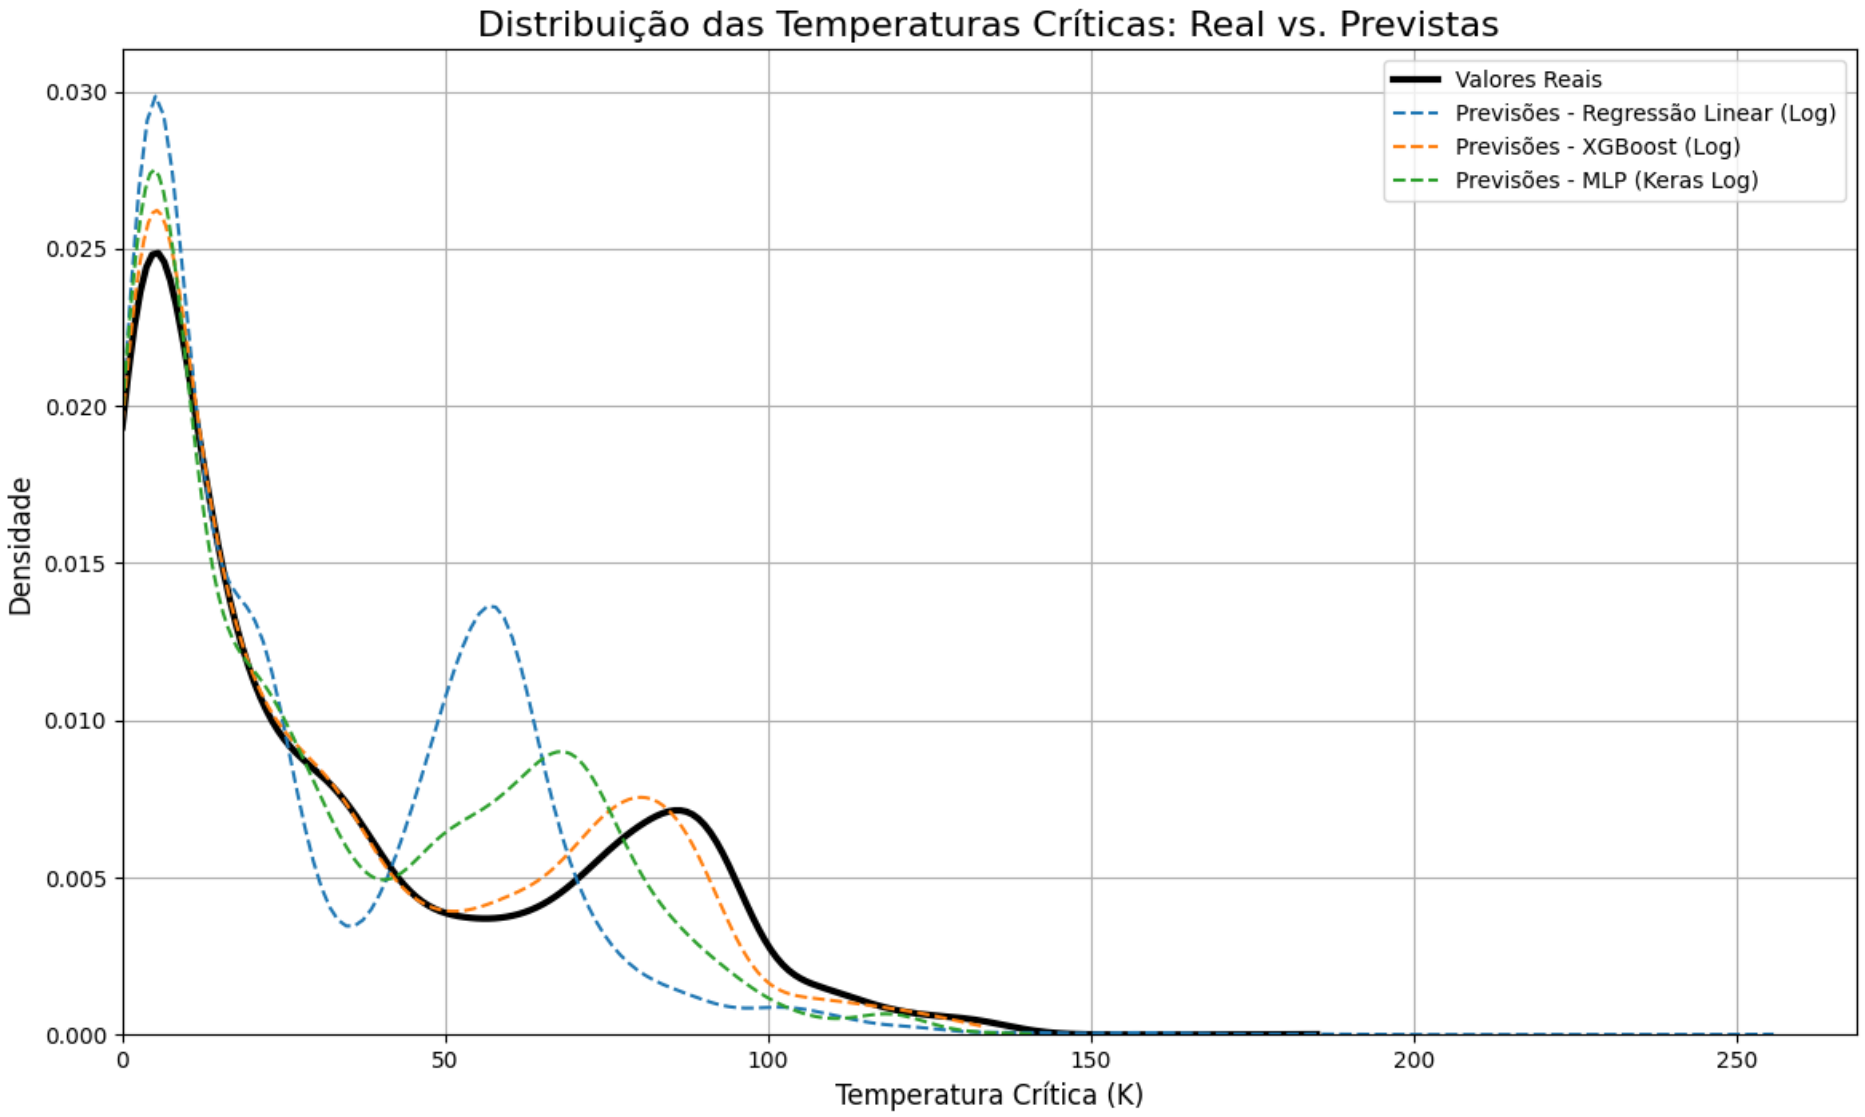

Conclusões

- É possível prever a temperatura crítica de supercondutores com alta precisão usando apenas dados da sua fórmula química.
- O modelo **XGBoost** demonstrou ser a ferramenta mais eficaz para esta tarefa, superando a Regressão Linear e a Rede Neural.
- A análise de importância revelou que propriedades físicas como a **condutividade térmica** são determinantes para a predição da T_c.
- Este trabalho valida a abordagem data-driven como um poderoso complemento à pesquisa experimental na busca por novos materiais.

Abordagens Alternativas no Campo

Nosso trabalho, baseado em Hamidieh (2018), usou um **modelo único de regressão**.

Uma abordagem alternativa importante, de Stanev et al. (2017), usa um modelo em **cascata**:

1. Primeiro, um modelo **classifica** o material como de alta ou baixa T_c.
2. Depois, um modelo de **regressão especialista** prevê a T_c para cada classe.
3. Após o treinamento, o modelo deverá ser capaz de **propor novos materiais** candidatos a supercondutores.

Discussão Crítica: Qual a Melhor Estratégia?

Modelo Único (Nosso Trabalho)

- **Vantagem:** Mais simples de implementar, treinar e manter.
- **Argumento:** Um modelo robusto como o XGBoost pode ser poderoso o suficiente para aprender as complexas interações sem precisar de uma pré-classificação.

Modelo em Cascata (Stanev et al.)

- **Vantagem:** Potencialmente mais preciso, pois treina modelos "especialistas" para diferentes regimes de T_c.
- **Argumento:** Pode revelar que diferentes features são importantes para supercondutores de alta e baixa temperatura.

Questão Aberta

A complexidade adicional da cascata justifica o ganho potencial de performance? A resposta pode depender do problema e dos dados específicos. Não há uma única "melhor" solução.

Próximo Passo: Da Predição à Descoberta

O objetivo final deste campo não é apenas prever, mas **descobrir novos materiais**.

- Modelos de ML como o nosso podem ser usados para "escanear" milhões de compostos químicos hipotéticos.

Próximo Passo: Da Predição à Descoberta

O objetivo final deste campo não é apenas prever, mas **descobrir novos materiais**.

- Modelos de ML como o nosso podem ser usados para "escanear" milhões de compostos químicos hipotéticos.
- O trabalho de Stanev et al. (2017), por exemplo, usou seu modelo para analisar 12.000 compostos e **propôs 60 novos candidatos** a supercondutores.

Próximo Passo: Da Predição à Descoberta

O objetivo final deste campo não é apenas prever, mas **descobrir novos materiais**.

- Modelos de ML como o nosso podem ser usados para "escanear" milhões de compostos químicos hipotéticos.
- O trabalho de Stanev et al. (2017), por exemplo, usou seu modelo para analisar 12.000 compostos e **propôs 60 novos candidatos** a supercondutores.
- **Futuro desse projeto:** Usar o modelo XGBoost treinado para gerar uma lista de novos materiais promissores para futura síntese e validação em laboratório.

Obrigado! Perguntas?

Referências I

- K. Hamidieh, *A Data-Driven Statistical Model for Predicting the Critical Temperature of a Superconductor*, arXiv:1803.10260v2 [stat.AP], 2018.
- V. Stanev, C. Oses, A. G. Kusne, et al., *Machine learning modeling of superconducting critical temperature*, arXiv:1709.02727v2 [cond-mat.supr-con], 2017.
- M. Geraldes, *Código-fonte da análise: supercondutores com ML e DL*, `github.com/Geraldes-Matheus/M.L-and-D.L`.
- C. E. da Silva, *Estudo básico sobre supercondutividade e suas aplicações*, Trabalho de Conclusão de Curso, Universidade Federal do Pará, 2015.